

Trabalho Final

1) Objetivo:

O objetivo deste trabalho é permitir que os alunos aprofundem seus conhecimentos em Processamento de Linguagem Natural (PLN) por meio da aplicação prática de técnicas e ferramentas estudadas em aula. Os alunos deverão escolher um tópico específico de PLN, implementar uma solução para um problema relacionado, e apresentar os resultados sob a forma de um artigo científico, seguindo normas acadêmicas.

2) Especificação

A. O trabalho deverá definir obrigatoriamente quatro pontos:

(i) Seleção de Tópico na área de PLN: selecionar, da lista abaixo (ou sugerir outro), o tópico de interesse. O tópico precisa ser aprovado pelos professores.

1) Análise de sentimentos	12) Sumarização de texto
2) Chatbots	13) Tradução automática
3) Desambiguação	14) Retrieval Augmented Generation
4) Detecção de discurso de ódio	15) Modelagem de tópicos
5) Detecção de plágio	16) Similaridade semântica
6) Detecção de spam	17) Aumento de dados
7) Inferência textual	18) Extração de informação
8) Reconhecimento de Entidades Nomeadas	19) Modelos multimodais
9) Reconhecimento de fala	20) Reranking
10) Perguntas e respostas	21) Dense retrieval
11) Simplificação de texto	22) Métricas de avaliação

(ii) Precisa haver alguma **conexão com linguagem natural** (i.e., não pode apenas usar um LLM para resolver uma tarefa que não envolva diretamente linguagem natural).

(iii) Precisa haver um **dataset anotado**, que pode ser escolhido à vontade, desde que possua um **ground truth** que permita a avaliação dos resultados.

(iv) Uso de técnicas baseadas em **Transformers**.

B. Etapas

- Pesquisar em livros, anais de congressos, periódicos, repositórios de código, sites de tecnologias etc. sobre como resolver a tarefa.
- Redigir uma proposta com breve descrição (cerca de 150 palavras) identificando: o tópico escolhido, o objetivo do trabalho e o conjunto de dados a ser utilizado.
- Desenvolver/implementar o trabalho proposto.
- Analisar em detalhes os resultados obtidos.

- (v) Escrever um artigo descrevendo o trabalho realizado e as constatações. O artigo deve conter entre **8 e 10 páginas** (excluindo referências) segundo ao formato da SBC (ver [este link](#))
- (vi) Preparar uma apresentação de **exatamente 15 minutos**.

C. Datas Importantes:

- 📅 Limite para a escolha dos tópicos/conjunto de dados (*i.e.*, preencher planilha): **08/04**
- 📅 Limite para a entrega da proposta: **22/04**
- 📅 Apresentação do andamento (2 minutos): **20/05**
- 📅 Apresentação final: **03/06, 10/06 e 17/06** (conforme sorteio)
- 📅 Entrega do artigo e código: **17/06**

D. Itens avaliados:

- o Pesquisa/implementação (Peso 45%): definição da questão de pesquisa, aplicação das técnicas adequadas, complexidade, metodologia e nível de profundidade.
- o Apresentação (Peso 25%): clareza, organização, sequência lógica e tempo.
- o Artigo (Peso 30%): clareza, organização, qualidade do texto e observação do limite de páginas.

E. Estrutura Sugerida para o Artigo:

- o Resumo ~150 palavras
- o Introdução ~1 página (contexto, motivação, questão de pesquisa)
- o Referencial Teórico ~1 ou 2 páginas (terminologia, conceitos utilizados no trabalho)
- o Trabalhos Relacionados ~1 ou 2 páginas (outros trabalhos sobre o mesmo tópico)
- o Metodologia ~2 ou 3 páginas (sequência de passos seguida no desenvolvimento do trabalho)
- o Experimentos/Resultados ~4 ou 5 páginas (descrever as ferramentas utilizadas, apresentar e analisar os resultados em detalhe)
- o Conclusão ~meia página (sumariza o trabalho feito e aponta possibilidades de trabalhos futuros)

F. Pontos Importantes:

- o O trabalho deve ser feito **individualmente**.
- o Tudo o que for escrito deve ser com **as suas próprias palavras** – cópias de sentenças ou parágrafos são consideradas plágio.
- o **Uso de IA generativa:** Qualquer uso de ferramentas de IA generativa deve ser explicitamente declarado no artigo. Os autores devem informar **quais ferramentas foram utilizadas, em quais etapas do trabalho e para quais finalidades** (por exemplo, geração de código, revisão de texto, brainstorming, etc.). Todo o conteúdo produzido com auxílio de IA — tanto código quanto texto — deve ser **integralmente revisado, validado e assumido como responsabilidade dos autores**.
- o Possivelmente haverá algum artigo/postagem de blog/código sobre o conjunto de dados escolhido. É possível reutilizar código encontrado na Internet (desde que esteja explicitamente referenciado). Contudo, o objetivo do trabalho é que **você dê a sua contribuição para o tópico escolhido**, não limitando-se a reproduzir o que já existe. Tal contribuição pode ser na análise dos resultados – realizando um tipo diferente de análise e/ou descobrindo novos insights sobre o tópico.

- o Não gostou dos tópicos sugeridos – onde buscar ideias de outros tópicos?
 - Avaliações do SemEval <https://semeval.github.io/>
 - Avaliações do PAN <https://pan.webis.de/>
 - Site NLPProgress <http://nlpprogress.com/>
 - Datasets de PLN no Kaggle <https://www.kaggle.com/datasets?tags=13204-NLP>
 - Datasets em português
 - i. <https://forum.ailab.unb.br/t/datasets-em-portugues/251>
 - ii. <https://metatext.io/datasets-list/portuguese-language>